

## **PROPOSAL RISET**

**“Optimalisasi Deteksi Penyakit Daun Jagung Menggunakan Preprocessing dan Teknik Augmentasi pada CNN”**



Muhammad Iqbal Fikri Robani Amin

21081010334

**Dosen Pengampu :**

Dr. Basuki Rahmat, S.Si, MT

**PROGRAM STUDI INFORMATIKA**

**FAKULTAS ILMU KOMPUTER**

**UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR**

**2024**

## **BAB I**

### **PENDAHULUAN**

#### **1.1 Latar Belakang**

Tanaman jagung merupakan salah satu komoditas utama dalam sektor pertanian di Indonesia. Jagung memiliki peran penting dalam memenuhi kebutuhan pangan dan pakan, serta menjadi bahan baku berbagai industri, seperti pembuatan bioetanol dan makanan olahan. Jagung juga menjadi sumber pendapatan bagi banyak petani di Indonesia, terutama di wilayah-wilayah yang bergantung pada hasil pertanian sebagai mata pencaharian utama. Namun, produktivitas jagung sering kali terancam oleh berbagai faktor, salah satunya adalah serangan penyakit pada daun.

Penyakit daun jagung seperti karat daun, bercak daun, bulai daun, dan hawar daun menjadi ancaman serius bagi keberlanjutan produksi jagung. Penyakit-penyakit ini dapat menurunkan kualitas dan kuantitas hasil panen, yang pada akhirnya memengaruhi pendapatan petani dan pasokan komoditas di pasar. Dampaknya tidak hanya dirasakan pada tingkat petani, tetapi juga dapat memengaruhi stabilitas ekonomi di sektor pertanian secara keseluruhan. Berdasarkan beberapa penelitian, penyakit hawar daun saja dapat menyebabkan kehilangan hasil hingga 70%. Sayangnya, data spesifik mengenai kerugian akibat penyakit daun jagung di Indonesia masih terbatas. Hal ini menunjukkan adanya kebutuhan mendesak untuk penelitian lebih lanjut yang dapat memberikan solusi praktis bagi para petani.

Kemajuan teknologi informasi dan pemrosesan data membuka peluang baru dalam mendeteksi dan mencegah penyakit daun jagung secara lebih efektif. Salah satu pendekatan yang menjanjikan adalah penggunaan teknologi deep learning, khususnya Convolutional Neural Network (CNN). CNN merupakan metode yang sangat efektif dalam mengenali pola dalam citra digital, sehingga cocok untuk digunakan dalam identifikasi penyakit daun berdasarkan gambar. CNN tidak hanya dapat memproses

citra dengan cepat, tetapi juga memiliki kemampuan untuk belajar secara otomatis dari data yang diberikan, sehingga mampu menghasilkan model deteksi yang andal.

Beberapa penelitian sebelumnya telah menunjukkan keberhasilan implementasi CNN dalam klasifikasi penyakit tanaman. Sebagai contoh, penelitian oleh Rizal Amegia Saputra dan tim (2021) menunjukkan bahwa arsitektur MobileNet dapat mencapai akurasi pengujian sebesar 89,3% untuk mendeteksi tiga jenis penyakit pada daun padi. Penelitian ini menunjukkan potensi besar CNN dalam membantu petani mengidentifikasi penyakit dengan cepat dan akurat. Penelitian lainnya oleh Tim Peneliti dari Politeknik Ujung Pandang (2020) menunjukkan bahwa CNN dengan arsitektur VGG16 dapat mendeteksi empat jenis penyakit daun jagung dengan akurasi sebesar 90,5%. Namun, penelitian ini masih memiliki keterbatasan, seperti kurangnya teknik augmentasi data untuk meningkatkan keragaman dataset, yang dapat memengaruhi performa model.

Di sisi lain, penelitian oleh Chrisno R. Kotta dan tim (2020) menggunakan arsitektur InceptionV3 untuk mendeteksi penyakit pada daun tomat dengan akurasi pengujian sebesar 94,5%. Penelitian ini menyoroti pentingnya penggunaan dataset yang besar dan beragam dalam meningkatkan performa model deep learning. Selain itu, penelitian oleh Nur Fadlia dan Rifki Kosasih (2019) menggunakan arsitektur ResNet-101 untuk mendeteksi tiga jenis penyakit pada daun padi, dengan akurasi pengujian sebesar 91%. Penelitian ini memanfaatkan transfer learning untuk meningkatkan akurasi model, meskipun cakupan kelas penyakit masih terbatas.

Meskipun hasil-hasil penelitian tersebut menunjukkan potensi besar CNN dalam klasifikasi penyakit tanaman, sebagian besar penelitian tersebut berfokus pada jenis tanaman selain jagung atau hanya mengidentifikasi satu jenis penyakit. Di Indonesia, penelitian mengenai deteksi penyakit daun jagung dengan teknologi deep learning masih sangat terbatas, baik dari segi dataset maupun metode yang digunakan. Padahal,

deteksi dini penyakit daun jagung sangat penting untuk mencegah penyebaran penyakit yang lebih luas dan mengurangi kerugian yang dihadapi petani.

Dengan latar belakang ini, penelitian ini bertujuan untuk mengembangkan model CNN yang mampu mendeteksi dan mengklasifikasikan beberapa jenis penyakit daun jagung secara komprehensif. Model ini diharapkan dapat membantu petani dalam mendeteksi penyakit secara dini, sehingga mereka dapat mengambil tindakan pencegahan yang tepat dan meningkatkan produktivitas serta kualitas hasil panen. Penelitian ini juga bertujuan untuk mengatasi beberapa keterbatasan dari penelitian sebelumnya, seperti penggunaan dataset yang terbatas dan kurangnya teknik augmentasi data. Dengan demikian, penelitian ini tidak hanya memberikan kontribusi pada pengembangan teknologi deteksi penyakit tanaman, tetapi juga mendukung keberlanjutan sektor pertanian di Indonesia.

## **1.2 Rumusan Masalah**

1. Bagaimana merancang model Convolutional Neural Network (CNN) yang mampu mendeteksi dan mengklasifikasikan berbagai jenis penyakit pada daun jagung dengan akurasi tinggi?
2. Bagaimana memanfaatkan teknik augmentasi data untuk meningkatkan keragaman dataset dan performa model dalam mendeteksi penyakit daun jagung?
3. Apa saja langkah preprocessing data yang optimal untuk meningkatkan akurasi model CNN dalam klasifikasi penyakit daun jagung?
4. Bagaimana mengevaluasi kinerja model CNN yang dikembangkan menggunakan metrik seperti akurasi, presisi, recall, dan F1-score?

5. Apa saja kendala utama dalam pengembangan model deteksi penyakit daun jagung, dan bagaimana solusi yang dapat diimplementasikan untuk mengatasi kendala tersebut?

### **1.3 Tujuan Penelitian**

1. Mengembangkan model Convolutional Neural Network (CNN) yang mampu mendeteksi dan mengklasifikasikan berbagai jenis penyakit pada daun jagung dengan tingkat akurasi yang tinggi.
2. Memanfaatkan teknik augmentasi data untuk meningkatkan keragaman dataset dan performa model CNN dalam mendeteksi penyakit daun jagung.
3. Mengidentifikasi langkah-langkah preprocessing data yang optimal untuk mendukung pengembangan model CNN yang efektif dan efisien.
4. Mengevaluasi kinerja model CNN menggunakan metrik akurasi, presisi, recall, dan F1-score untuk memastikan keandalan model dalam mendeteksi penyakit daun jagung.
5. Memberikan solusi terhadap kendala utama dalam pengembangan model deteksi penyakit daun jagung, serta merekomendasikan langkah-langkah pengembangan lebih lanjut.

### **1.4 Batasan Masalah**

1. Penelitian ini hanya berfokus pada pengembangan model deteksi penyakit daun jagung menggunakan metode Convolutional Neural Network (CNN).

2. Dataset yang digunakan dalam penelitian ini terdiri dari gambar daun jagung dengan kategori karat daun, bercak daun, bulai daun, hawar daun, dan daun sehat.
3. Teknik augmentasi data yang diterapkan terbatas pada metode dasar seperti rotasi, flipping, scaling, dan perubahan pencahayaan untuk meningkatkan keragaman dataset.
4. Evaluasi kinerja model hanya dilakukan menggunakan metrik akurasi, presisi, recall, dan F1-score tanpa mempertimbangkan aspek waktu pemrosesan pada perangkat dengan sumber daya terbatas.
5. Ruang lingkup penelitian ini terbatas pada tanaman jagung dan tidak mencakup tanaman lain atau pengelompokan penyakit tanaman secara umum.
6. Penelitian ini tidak mencakup pengembangan aplikasi berbasis mobile atau web untuk implementasi model CNN, melainkan hanya fokus pada pengembangan dan evaluasi model klasifikasi.

Dengan batasan masalah yang jelas, penelitian ini diharapkan dapat menghasilkan kontribusi yang signifikan dalam pengembangan solusi deteksi dini penyakit daun jagung menggunakan teknologi deep learning. Selain itu, penelitian ini diharapkan membuka peluang bagi pengembangan lebih lanjut di masa depan untuk mencakup ruang lingkup yang lebih luas, seperti integrasi model dengan aplikasi berbasis mobile atau web untuk membantu petani secara langsung.

## **BAB II**

### **TINJAUAN PUSTAKA**

#### **2.1 Penelitian Terdahulu**

Penelitian terdahulu menunjukkan bahwa implementasi deep learning, khususnya Convolutional Neural Network (CNN), sangat efektif untuk mendeteksi penyakit daun jagung. CNN dikenal dengan kemampuannya dalam mengekstraksi fitur secara otomatis dari citra, memungkinkan deteksi penyakit dengan akurasi tinggi. Sebagai contoh, penelitian Çetiner (2023) menggunakan CNN untuk mendeteksi Blight, Common Rust, dan Grey Leaf Spot pada daun jagung. Malik et al. (2022) menekankan pentingnya deteksi dini penyakit untuk meningkatkan hasil panen dan kualitas tanaman melalui teknik pengolahan citra berbasis CNN. Arsitektur CNN seperti VGG-19 telah terbukti efektif dalam penelitian Elumalai (2023) untuk klasifikasi penyakit daun tanaman dengan akurasi tinggi. Penelitian KOKATE (2023) juga mendukung klaim ini dengan menunjukkan bahwa penggunaan arsitektur CNN yang tepat mampu meningkatkan akurasi deteksi penyakit tanaman. Selain itu, penggunaan TensorFlow Lite untuk aplikasi mobile (Latif et al. 2022) menunjukkan potensi implementasi model ringan yang tetap akurat untuk deteksi penyakit tanaman.

Preprocessing citra merupakan aspek penting yang mendukung performa model CNN. Teknik seperti resizing, normalisasi, dan augmentasi data sering digunakan untuk memastikan model dapat mempelajari fitur yang relevan dari citra input. Penelitian Meena et al. (2021) menunjukkan bahwa penggunaan preprocessing yang tepat dapat meningkatkan akurasi model hingga 10% dibandingkan model yang dilatih tanpa preprocessing. Selain itu, penelitian oleh Yusoff et al. (2023) menyoroti pentingnya ekstraksi fitur berbasis warna dan tekstur untuk mendeteksi perubahan visual pada daun akibat serangan penyakit. Penggunaan teknik ini membantu meningkatkan akurasi deteksi, terutama untuk dataset dengan ukuran terbatas.

Penelitian ini juga menunjukkan bahwa kombinasi metode CNN dengan teknik tradisional seperti analisis histogram dapat memberikan hasil yang lebih baik.

Secara keseluruhan, penelitian terdahulu menyoroti pentingnya pemilihan arsitektur, teknik preprocessing citra seperti resizing dan normalisasi, serta ekstraksi fitur yang tepat untuk meningkatkan performa model CNN dalam mendeteksi penyakit tanaman, termasuk daun jagung. Penelitian lebih lanjut diperlukan untuk mengembangkan model yang lebih efisien dengan akurasi tinggi, terutama untuk diterapkan dalam skala besar di sektor pertanian. Selain itu, fokus pada pengembangan dataset yang lebih beragam dan representatif juga menjadi aspek penting untuk meningkatkan kemampuan model dalam mendeteksi penyakit secara lebih luas. Dengan demikian, penelitian mendalam mengenai berbagai arsitektur CNN dan teknik pengolahan citra yang canggih sangat diperlukan untuk mendukung pertanian modern berbasis teknologi.

## **2.2 Landasan Teori**

### **2.2.1 Tanaman Jagung dan Penyakitnya**

Jagung (*Zea mays L.*) adalah salah satu komoditas pangan penting di dunia, termasuk Indonesia. Tanaman ini memiliki nilai ekonomi tinggi karena digunakan sebagai bahan pangan, pakan ternak, dan bahan baku industri. Jagung memiliki karakteristik yang fleksibel dalam adaptasi lingkungan sehingga dapat ditanam di berbagai daerah. Namun, produktivitas jagung sering menghadapi tantangan, terutama akibat serangan penyakit. Penyakit yang menyerang tanaman jagung dapat menyebabkan kerugian ekonomi yang signifikan karena mengurangi hasil panen secara langsung. Penyakit seperti Hawar Daun yang disebabkan oleh jamur *Exserohilum turcicum* ditandai dengan bercak memanjang berwarna abu-abu hingga coklat pada daun yang dapat mengurangi kemampuan fotosintesis tanaman. Penyakit lain adalah Bercak Daun yang disebabkan oleh jamur *Bipolaris maydis*. Gejalanya berupa bercak oval berwarna coklat kemerahan pada daun dan serangan berat dapat menyebabkan



daun mengering sebelum waktunya. Sementara itu, Karat Daun yang disebabkan oleh jamur *Puccinia sorghi* ditandai dengan pustula kecil berwarna coklat kemerahan pada permukaan daun dan dapat menghambat pertumbuhan tanaman serta mengurangi hasil panen.

Metode tradisional untuk mendeteksi penyakit pada daun jagung sering kali melibatkan pengamatan visual oleh ahli agronomi atau petani yang berpengalaman. Namun, metode ini memiliki keterbatasan seperti ketergantungan pada keahlian individu, waktu yang lama, dan kesalahan dalam identifikasi akibat gejala yang serupa pada beberapa penyakit. Oleh karena itu, deteksi dini menggunakan teknologi berbasis citra digital dan algoritma deep learning seperti CNN menjadi solusi yang menjanjikan. Teknologi ini tidak hanya mampu meningkatkan akurasi deteksi tetapi juga memberikan hasil yang lebih cepat dan konsisten dibandingkan metode konvensional.

### **2.2.2 Deep Learning**

Deep learning adalah cabang dari machine learning yang menggunakan jaringan saraf tiruan (Artificial Neural Network - ANN) dengan banyak lapisan untuk memproses data kompleks seperti gambar, suara, dan teks. Model deep learning dirancang untuk mempelajari representasi data secara hierarkis, di mana lapisan awal fokus pada fitur sederhana seperti tepi dan sudut, sedangkan lapisan yang lebih dalam menangkap fitur kompleks yang lebih abstrak. Dalam deep learning, model secara otomatis mempelajari representasi data melalui proses pembelajaran yang disebut backpropagation. Proses ini melibatkan pembaruan bobot berdasarkan gradien error yang dihitung dari selisih antara prediksi model dan label sebenarnya.

Keunggulan utama deep learning terletak pada kemampuannya untuk bekerja dengan data yang tidak terstruktur dan mengenali pola-pola yang kompleks. Selain itu, model deep learning mampu mengekstrak fitur otomatis tanpa memerlukan proses manual, fleksibel dalam bekerja dengan data besar dan beragam, serta menghasilkan akurasi tinggi untuk berbagai aplikasi. Salah satu penerapan utama deep learning

adalah dalam bidang pengolahan citra, di mana model seperti CNN digunakan untuk klasifikasi, deteksi objek, dan segmentasi. Deep learning juga digunakan dalam berbagai aplikasi lainnya, termasuk pemrosesan bahasa alami, analisis suara, dan prediksi berbasis data waktu nyata.

### **2.2.3 Convolutional Neural Network (CNN)**

CNN adalah jenis jaringan saraf tiruan yang dirancang khusus untuk memproses data berbasis gambar. CNN terdiri dari beberapa lapisan utama yang bekerja secara sinergis untuk mengekstrak dan menganalisis fitur gambar. Lapisan pertama adalah Convolutional Layer, yang menggunakan kernel atau filter untuk mengekstraksi fitur dasar seperti tepi, tekstur, dan pola. Proses konvolusi ini menghasilkan peta fitur yang merepresentasikan karakteristik penting dari data visual. Setelah itu, Pooling Layer digunakan untuk mengurangi dimensi data dengan mempertahankan informasi penting, sehingga mempercepat komputasi dan mengurangi risiko overfitting. Metode pooling yang umum digunakan adalah max pooling, di mana nilai maksimum dari setiap area yang diproses dipilih.

Pada tahap berikutnya, Flattening Layer meratakan peta fitur menjadi vektor satu dimensi untuk digunakan dalam lapisan Fully Connected Layer. Lapisan ini bertugas menggabungkan semua fitur yang telah diekstraksi untuk menghasilkan output akhir berupa prediksi kelas. CNN memiliki keunggulan utama dalam menangani data visual karena dirancang untuk mengolah citra secara langsung tanpa memerlukan ekstraksi fitur manual. Kemampuan ini membuat CNN menjadi salah satu pendekatan paling efektif untuk aplikasi klasifikasi citra, termasuk deteksi penyakit tanaman berdasarkan gambar daun.

### **2.2.4 Dataset**

Dataset adalah komponen penting dalam pelatihan model deep learning. Dataset yang baik harus mencakup berbagai kondisi yang representatif dari data nyata, termasuk variasi pencahayaan, sudut pengambilan gambar, dan kondisi daun yang

beragam. Dataset yang digunakan dalam penelitian ini berasal dari Kaggle dengan rincian data sebanyak 3718 gambar daun sehat dan 3814 gambar daun berpenyakit. Dataset ini dibagi menjadi dua bagian utama, yaitu Training Data sebesar 60 persen dari total dataset digunakan untuk melatih model, sedangkan Testing Data sebesar 40 persen digunakan untuk menguji performa model. Teknik augmentasi data seperti flipping, rotasi, perubahan pencahayaan, dan scaling digunakan untuk meningkatkan keragaman dataset sehingga model dapat lebih robust terhadap variasi dalam data nyata. Teknik ini juga membantu mencegah overfitting dengan memastikan bahwa model dilatih pada data yang lebih bervariasi. Dataset yang lebih beragam memungkinkan model untuk belajar dari berbagai pola dan kondisi, sehingga meningkatkan generalisasi model saat diaplikasikan pada data baru.

### **2.2.5 Confusion Matrix**

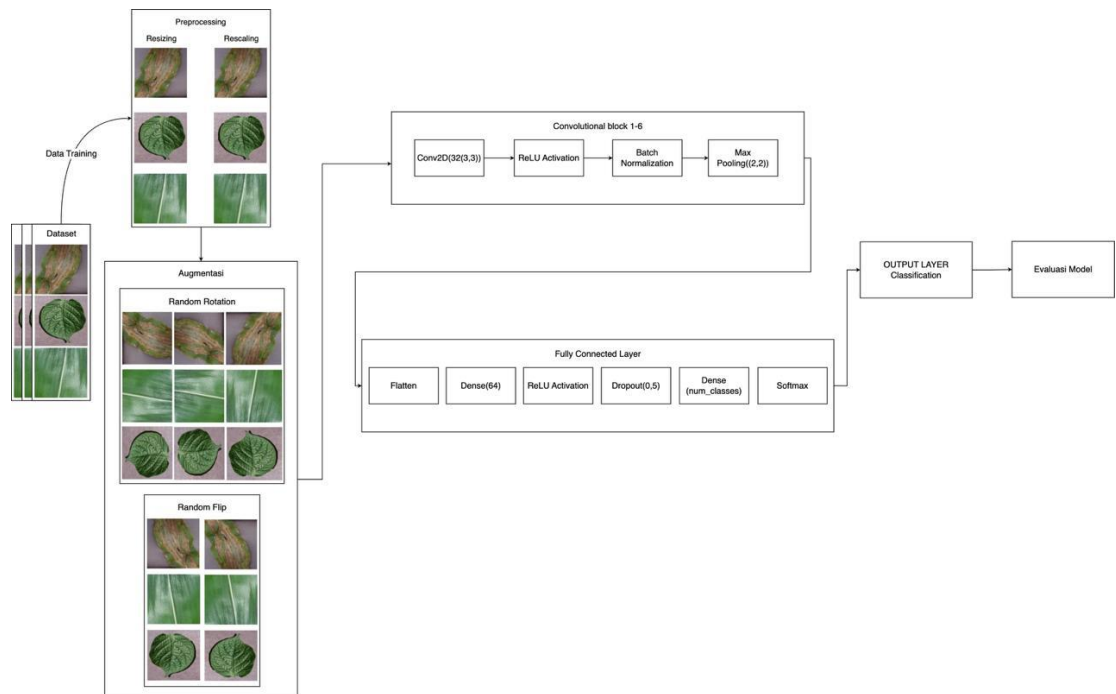
Confusion matrix adalah alat evaluasi yang digunakan untuk mengukur kinerja model klasifikasi. Matriks ini terdiri dari empat elemen utama, yaitu True Positive (TP) untuk prediksi benar pada kelas positif, True Negative (TN) untuk prediksi benar pada kelas negatif, False Positive (FP) untuk prediksi salah pada kelas positif, dan False Negative (FN) untuk prediksi salah pada kelas negatif. Berdasarkan confusion matrix, metrik evaluasi seperti akurasi, precision, recall, dan F1-score dapat dihitung menggunakan rumus yang telah ditentukan. Akurasi mengukur proporsi prediksi yang benar terhadap total data, sedangkan precision menunjukkan sejauh mana prediksi positif benar dari seluruh prediksi positif. Recall mengukur sejauh mana model berhasil menangkap semua data positif, dan F1-score adalah rata-rata harmonis antara precision dan recall. Dengan menggunakan confusion matrix, analisis mendalam terhadap kesalahan model dapat dilakukan, misalnya dengan mengidentifikasi kelas mana yang paling sering salah diprediksi. Hal ini memungkinkan perbaikan model melalui teknik tambahan seperti fine-tuning atau penyesuaian dataset untuk meningkatkan performa secara keseluruhan.

## BAB III

### METODOLOGI PENELITIAN

#### 3.1 Desain Penelitian

Penelitian ini menggunakan model pembelajaran mendalam yang mengadopsi algoritma Convolutional Neural Network (CNN) untuk identifikasi dan klasifikasi penyakit daun jagung. Kerangka metodologi yang digunakan mencakup langkah-langkah berikut: pengumpulan data, prapemrosesan data, augmentasi data, pengembangan model, pelatihan, dan evaluasi kinerja model. Tahapan-tahapan ini disusun secara sistematis untuk memastikan bahwa model yang dihasilkan memiliki performa tinggi dalam mengklasifikasikan penyakit daun jagung secara akurat (R. A. Pangestu et al., 2020; V. C. Khade dan S. B. Patil, 2023).



Gambar 1. Block Diagram

Pada diagram tersebut, alur penelitian dimulai dari proses pengumpulan data berupa gambar daun jagung. Data ini kemudian diproses melalui tahap preprocessing

yang mencakup resizing untuk menyamakan dimensi gambar dan rescaling untuk normalisasi nilai piksel. Selanjutnya, dilakukan augmentasi data dengan teknik Random Rotation dan Random Flip untuk meningkatkan keragaman dataset (L. Perez dan J. Wang, 2017). Setelah tahap augmentasi, data dimasukkan ke dalam arsitektur CNN yang terdiri dari beberapa lapisan konvolusi, aktivasi ReLU, batch normalization, dan max pooling untuk ekstraksi fitur. Hasil dari lapisan konvolusi diratakan melalui flatten layer dan diteruskan ke fully connected layer untuk klasifikasi akhir. Lapisan softmax digunakan pada output layer untuk menghasilkan probabilitas klasifikasi untuk setiap kelas penyakit. Proses terakhir adalah evaluasi model, di mana kinerja model diukur menggunakan metrik seperti akurasi, presisi, recall, dan F1-score untuk memastikan kemampuan model dalam mendeteksi penyakit daun jagung secara akurat (A. A. Kadam et al., 2023).

## **3.2 Model Architecture and Process Flow**

### **3.2.1 Pengumpulan Data**

Dalam penelitian ini, fase awal mengharuskan akuisisi kumpulan data yang relevan untuk tujuan eksperimen. Data dikompilasi menggunakan dataset yang dapat diakses secara terbuka, seperti dataset "Bangladeshi Crops Disease" dari platform Kaggle. Dataset ini terdiri dari lebih dari 31.100 gambar yang menggambarkan berbagai penyakit tanaman (V. C. Khade dan S. B. Patil, 2023). Untuk penelitian ini, fokus diarahkan pada subset dataset yang mencakup penyakit daun jagung. Data ini mencakup dua kelas utama, yaitu daun sehat dan daun yang terinfeksi penyakit. Pemilihan dataset yang berkualitas dan representatif sangat penting untuk memastikan bahwa model dapat belajar dari pola-pola penyakit secara efektif (H. Hamidson et al., 2019).

### **3.2.2 Preprocessing Data**

Data yang telah dikumpulkan diproses untuk meningkatkan kualitas sebelum digunakan dalam pelatihan model. Langkah-langkah preprocessing meliputi resizing dan rescaling nilai piksel.

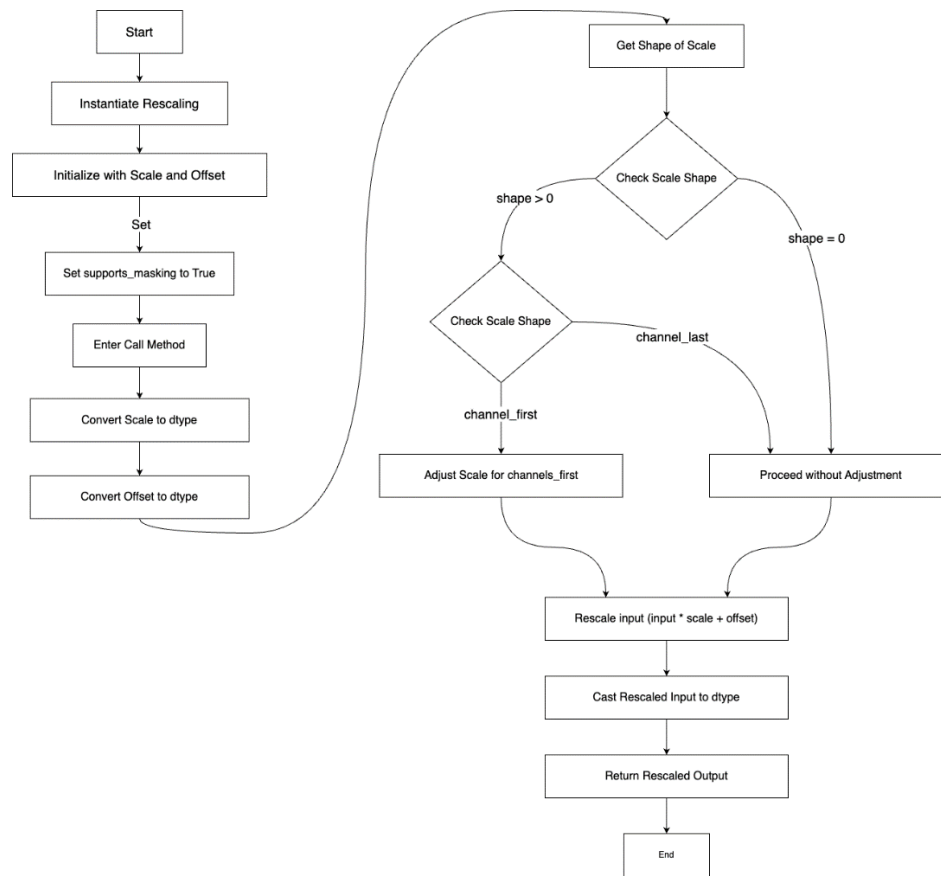
1. Resizing Resizing adalah proses mengubah ukuran gambar ke dimensi yang seragam untuk memastikan model deep learning dapat memproses input secara konsisten.



Gambar 2. Alur Resizing

Dalam **Gambar 2**. Alur Resizing tersebut, proses resizing dimulai dengan inisialisasi parameter, yaitu tinggi dan lebar target gambar, serta metode interpolasi yang digunakan untuk menghitung nilai piksel baru selama perubahan ukuran. Setelah itu, data gambar diperiksa untuk menentukan formatnya, apakah dalam mode `channel_last` (format RGB umum) atau `channel_first` (format yang digunakan dalam beberapa framework). Format ini penting untuk memastikan kompatibilitas data dengan model. Gambar kemudian diubah ukurannya berdasarkan format yang terdeteksi. Setelah proses resizing selesai, sistem memeriksa apakah rasio aspek gambar perlu disesuaikan. Jika diperlukan, ada tiga opsi yang dapat diterapkan: gambar dapat dipotong untuk menyesuaikan rasio target tanpa distorsi, diberi padding untuk mempertahankan rasio aspek tanpa mengubah isi gambar, atau langsung diubah ukurannya tanpa mempertimbangkan rasio aspek. Jika padding digunakan, area kosong yang ditambahkan diisi dengan nilai tertentu, seperti nol atau rata-rata piksel. Akhirnya, gambar yang telah diubah ukurannya dan disesuaikan dengan rasio aspek dikembalikan sebagai output yang siap digunakan untuk pelatihan atau pengujian model.

2. Rescaling Rescaling adalah langkah penting dalam preprocessing yang bertujuan untuk normalisasi data dengan mengubah nilai piksel dari rentang  $[0, 255]$  menjadi  $[0, 1]$ . [14] proses ini penting karena data yang dinormalisasi memungkinkan model machine learning untuk belajar lebih cepat dan stabil dengan menghindari gradien yang terlalu besar dalam propagasi mundur (backpropagation).



Gambar 3. Alur Rescaling

Dalam **Gambar 3**. Alur Rescaling tersebut, proses rescaling dimulai dengan inisialisasi parameter utama, yaitu nilai scale dan offset. Scale digunakan untuk menentukan faktor pengali untuk normalisasi nilai piksel, sementara offset digunakan untuk menambahkan nilai tertentu ke hasil normalisasi. Setelah parameter diinisialisasi, tipe data (dtype) dari scale dan offset dikonversi agar kompatibel dengan data gambar yang akan diproses.

Tahap berikutnya adalah memeriksa bentuk (shape) dari scale. Jika bentuknya lebih besar dari nol, maka parameter disesuaikan dengan format data gambar, yaitu channel\_last atau channel\_first. Jika data berada dalam format channel\_first, penyesuaian skala dilakukan agar sesuai dengan susunan data



tersebut. Sebaliknya, jika format data adalah `channel_last`, proses dapat langsung dilanjutkan tanpa penyesuaian tambahan.

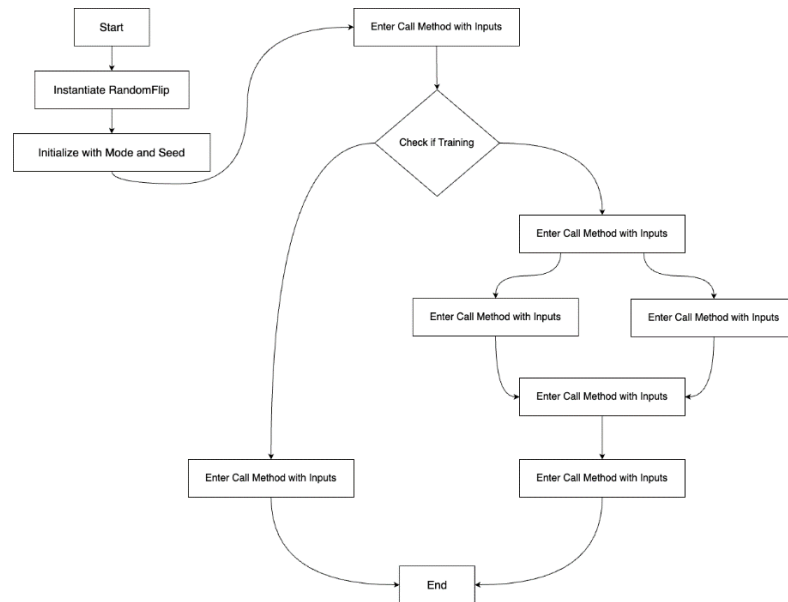
Setelah itu, proses normalisasi ini dilakukan dengan mengalikan nilai piksel gambar dengan scale dan menambahkan offset. Data hasil normalisasi kemudian dikonversi kembali ke tipe data yang sesuai untuk memastikan kompatibilitas dengan langkah selanjutnya dalam pipeline model. Hasil akhir dari proses rescaling ini adalah data gambar dengan nilai piksel yang telah dinormalisasi ke dalam rentang  $[0,1][0,1][0,1]$ , sehingga siap digunakan dalam pelatihan atau pengujian model.

### **3.2.3 Augmentasi Data**

Augmentasi data dilakukan untuk meningkatkan variasi dalam dataset tanpa menambah data baru. Teknik augmentasi yang digunakan mencakup:

1. **RandomFlip** adalah teknik augmentasi data yang meningkatkan keragaman dataset gambar dengan membalik gambar secara acak secara horizontal, vertikal, atau keduanya (Z. Zhang et al., 2024). Pendekatan ini membuat model lebih tangguh terhadap variasi orientasi gambar yang mungkin muncul dalam data nyata, memungkinkan model mengenali pola meskipun orientasi gambar berubah. Efektivitas teknik seperti flipping dalam augmentasi data untuk meningkatkan kinerja klasifikasi gambar telah dibahas dalam literatur. Misalnya, Perez dan Wang (2017) meneliti berbagai teknik augmentasi data, termasuk flipping, dan menemukan bahwa metode ini secara signifikan meningkatkan kinerja model dalam tugas klasifikasi gambar. Dalam proses **RandomFlip**, parameter yang digunakan mencakup mode flipping (horizontal, vertikal, atau keduanya) dan seed untuk memastikan konsistensi hasil augmentasi jika diperlukan. Flipping dilakukan secara acak pada gambar input sesuai dengan konfigurasi yang telah ditentukan, menciptakan variasi orientasi yang membantu model memahami pola visual dengan lebih baik. **Random**

Rotation Memutar gambar dengan sudut acak untuk melatih model mengenali pola meskipun terdapat variasi orientasi (B. A. Riyadi et al., 2023).



Gambar 4. Random Flip

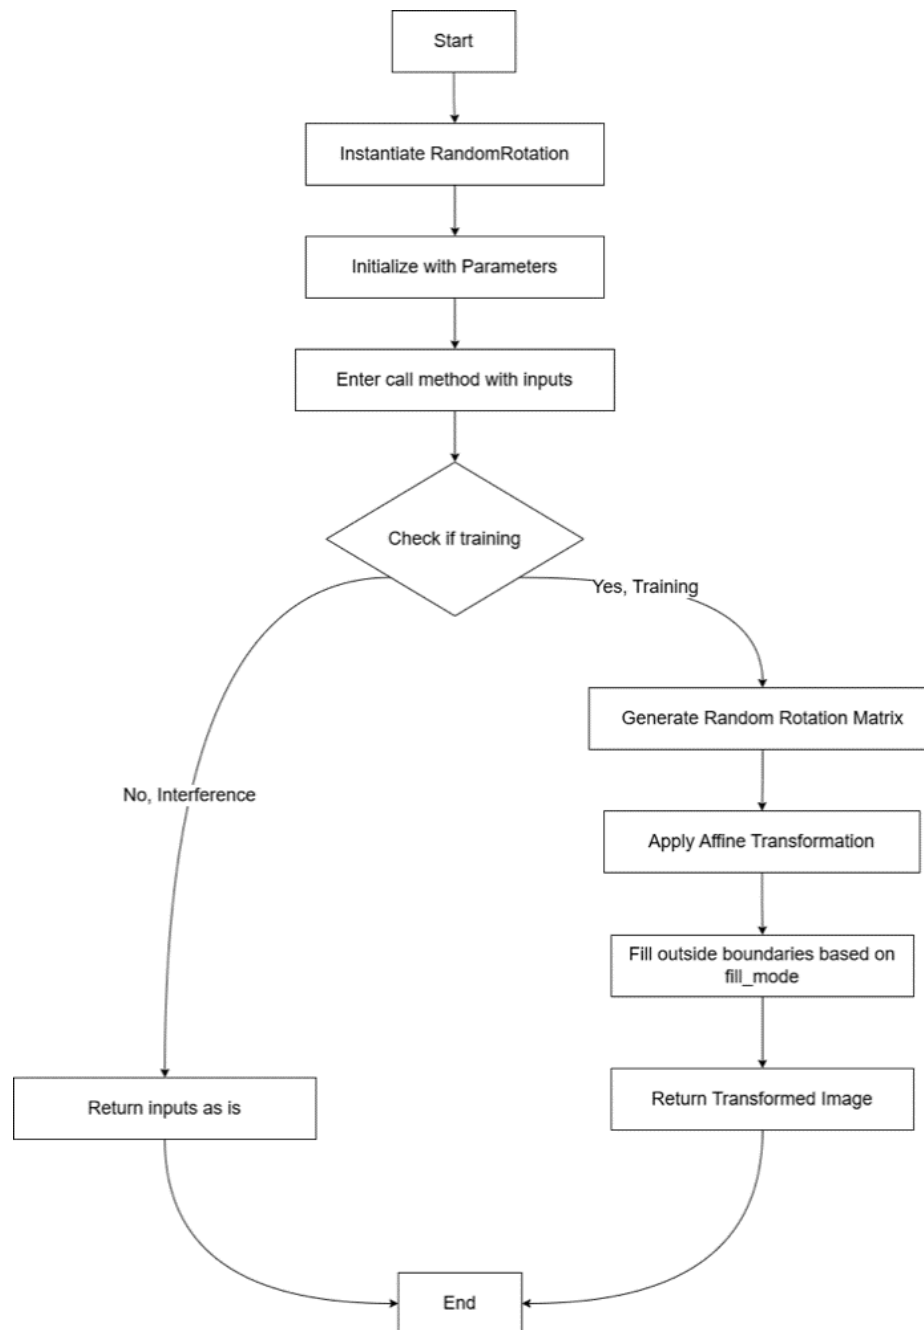
Dalam **Gambar 4.** Alur RandomFlip tersebut, proses RandomFlip dimulai dengan inisialisasi fungsi augmentasi. Parameter yang digunakan mencakup mode flipping (horizontal, vertikal, atau keduanya) dan seed untuk memastikan konsistensi hasil augmentasi jika diperlukan. Setelah inisialisasi, metode utama call dipanggil untuk mulai memproses gambar input.

Sistem kemudian memeriksa apakah proses sedang dilakukan dalam mode pelatihan atau inferensi. Jika model berada dalam mode pelatihan, flipping diterapkan secara acak sesuai dengan parameter mode yang telah ditentukan. Langkah ini memastikan bahwa augmentasi data dilakukan hanya selama pelatihan untuk meningkatkan kemampuan generalisasi model. Namun, jika dalam mode inferensi, gambar dilewatkan tanpa modifikasi untuk menjaga keakuratan prediksi pada data nyata.

Setelah memastikan mode pelatihan, flipping dilakukan pada gambar input sesuai dengan parameter yang diberikan. Gambar dapat dibalik secara horizontal, vertikal, atau keduanya, tergantung pada konfigurasi. Proses ini menciptakan variasi orientasi gambar yang membantu model dalam memahami pola visual meskipun gambar memiliki orientasi yang berbeda dari data latih awal.

Hasil akhir dari proses RandomFlip adalah gambar yang telah diubah orientasinya secara acak (jika dalam mode pelatihan) atau gambar asli (jika dalam mode inferensi). Gambar hasil augmentasi ini kemudian digunakan sebagai input untuk langkah pemrosesan model selanjutnya.

2. RandomRotation adalah teknik augmentasi data yang memutar gambar secara acak dengan sudut tertentu (B. A. Riyadi et al., 2023). Teknik ini bertujuan untuk meningkatkan keragaman data dengan menciptakan variasi orientasi gambar. Dengan rotasi ini, model dapat dilatih untuk mengenali pola dalam gambar meskipun objek berada pada sudut yang berbeda dari data aslinya (K. Alomar et al., 2023). Selama proses RandomRotation, parameter seperti rentang sudut rotasi dan metode pengisian untuk area di luar batas gambar diatur sesuai dengan konfigurasi yang telah ditentukan. Matriks transformasi rotasi acak dihasilkan berdasarkan parameter sudut, dan jika rotasi menghasilkan area kosong, metode pengisian seperti warna konstan atau interpolasi piksel diterapkan untuk menjaga keutuhan gambar. Teknik ini membantu model dalam memahami pola visual meskipun gambar memiliki orientasi yang berbeda.



Gambar 5. Random Rotation

Dalam **Gambar 5**. Alur RandomRotation tersebut, proses RandomRotation dimulai dengan inialisasi fungsi augmentasi, termasuk parameter seperti

rentang sudut rotasi dan metode pengisian (*fill mode*) untuk area di luar batas gambar. Parameter ini memastikan bahwa rotasi dilakukan sesuai konfigurasi yang telah ditentukan.

Setelah inisialisasi, metode utama `call` dipanggil untuk memproses gambar input. Langkah pertama adalah memeriksa apakah model sedang berada dalam mode pelatihan atau inferensi. Jika model dalam mode pelatihan, rotasi acak diterapkan untuk meningkatkan variasi data. Sebaliknya, jika model berada dalam mode inferensi, gambar dilewatkan tanpa modifikasi untuk memastikan hasil prediksi tidak terpengaruh oleh augmentasi.

Selama proses rotasi, matriks transformasi rotasi acak dihasilkan berdasarkan parameter sudut yang telah ditentukan. Matriks ini kemudian digunakan dalam transformasi affine untuk menerapkan rotasi pada gambar. Jika rotasi menghasilkan area kosong di luar batas gambar, area tersebut diisi menggunakan metode yang telah ditentukan oleh parameter *fill mode*, seperti warna konstan atau interpolasi piksel di sekitarnya.

Hasil akhir dari proses ini adalah gambar yang telah dirotasi secara acak (jika dalam mode pelatihan) atau gambar asli (jika dalam mode inferensi). Gambar hasil augmentasi ini kemudian digunakan sebagai input untuk langkah-langkah pemrosesan model selanjutnya.

Teknik augmentasi ini membantu model menggeneralisasi lebih baik pada data baru dengan menciptakan dataset yang lebih beragam.

### **3.2.4 Pembangunan Model**

Arsitektur CNN dirancang dengan memanfaatkan berbagai lapisan yang saling mendukung untuk mendeteksi fitur penting dari gambar daun jagung. Lapisan pertama adalah Convolutional Layer, yang bertugas mengekstraksi fitur dasar seperti tepi dan

tekstur. Lapisan ini bekerja dengan menerapkan filter atau kernel pada citra input untuk menghasilkan peta fitur. Selanjutnya, Activation Layer dengan fungsi ReLU digunakan untuk mempercepat proses pelatihan dengan menghilangkan nilai negatif dalam peta fitur. Setelah itu, Batch Normalization diterapkan untuk menstabilkan distribusi data selama proses pelatihan, yang bertujuan untuk mempercepat konvergensi model dan mengurangi masalah vanishing gradient.

Max Pooling Layer digunakan untuk mengurangi dimensi peta fitur tanpa menghilangkan informasi penting. Lapisan ini memilih nilai maksimum dari area tertentu dalam peta fitur, yang membantu mengurangi kompleksitas komputasi. Hasil dari Max Pooling Layer diratakan menggunakan Flatten Layer menjadi vektor satu dimensi. Vektor ini kemudian diteruskan ke Fully Connected Layer, yang bertugas menggabungkan semua fitur yang telah diekstraksi untuk menghasilkan prediksi akhir. Prediksi ini dilakukan oleh lapisan terakhir, yaitu Softmax Layer, yang mengubah output menjadi probabilitas untuk setiap kelas penyakit. Dengan arsitektur ini, model CNN dioptimalkan untuk mendeteksi pola-pola penting pada gambar daun jagung dengan efisiensi tinggi (S. Rizal Amegia et al., 2021).

### **3.2.5 Pelatihan Model**

Pelatihan dilakukan menggunakan optimizer Adam, yang dikenal dengan efisiensi dalam mempercepat proses pembelajaran. Fungsi loss yang digunakan adalah Categorical Crossentropy, yang cocok untuk klasifikasi multi-kelas. Model dilatih selama sejumlah epoch tertentu, dengan setiap epoch mencakup iterasi melalui seluruh dataset. Data validasi digunakan untuk memantau performa model selama pelatihan dan menghindari overfitting (R. Riri, 2023).

### **3.2.6 Evaluasi Model**

Evaluasi model dilakukan dengan menggunakan confusion matrix untuk menghitung metrik evaluasi seperti akurasi, presisi, recall, dan F1-score. Metrik-metrik ini memberikan gambaran menyeluruh mengenai kemampuan model dalam

mengklasifikasikan gambar secara akurat. Hasil evaluasi dibandingkan dengan tujuan awal penelitian untuk memastikan bahwa model yang dikembangkan memenuhi standar akurasi dan keandalan yang diharapkan (A. A. Kadam et al., 2023; C. R. Kotta et al., 2022).

### 3.2.7 Confusion Matrix

Confusion matrix adalah alat evaluasi yang digunakan untuk mengukur kinerja model klasifikasi. Matriks ini terdiri dari empat elemen utama, yaitu True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). True Positive (TP) mengacu pada jumlah prediksi benar untuk kelas positif, sedangkan True Negative (TN) adalah jumlah prediksi benar untuk kelas negatif. False Positive (FP) adalah jumlah prediksi salah, di mana kelas negatif diprediksi sebagai positif, dan False Negative (FN) adalah jumlah prediksi salah, di mana kelas positif diprediksi sebagai negatif. Confusion matrix memberikan informasi mendalam mengenai bagaimana model membuat prediksi untuk setiap kelas. Berdasarkan matriks ini, metrik evaluasi seperti :

1. Akurasi mengukur proporsi prediksi yang benar terhadap total data.

$$Akurasi = \frac{(TP + TN)}{(TP + FP + TN + FN)}$$

2. Presisi mengukur seberapa tepat prediksi kelas positif.

$$Presisi = \frac{TP}{(TP + FP)}$$

3. Recall mengukur seberapa baik model mendeteksi semua kasus positif.

$$recall = \frac{TP}{(TP + FN)}$$

4. F1-score. dan F1-score adalah rata-rata harmonis antara presisi dan recall.

$$Skor F-1 = \frac{(2 * recall * presisi)}{(recall + presisi)}$$

Dengan menggunakan confusion matrix, peneliti dapat menganalisis kekuatan dan kelemahan model, serta melakukan penyesuaian jika diperlukan untuk meningkatkan kinerjanya. Confusion matrix juga sangat berguna dalam mengevaluasi performa model pada dataset yang memiliki distribusi kelas yang tidak seimbang.



## DAFTAR PUSTAKA

- [1] "BAB II.pdf." Diakses: 8 Desember 2024. [Daring]. Tersedia pada:  
[https://repository.ub.ac.id/id/eprint/7832/3/BAB%20II.pdf?utm\\_source=chatgpt.com](https://repository.ub.ac.id/id/eprint/7832/3/BAB%20II.pdf?utm_source=chatgpt.com)
- [2] H. Hamidson, S. Suwandi, dan T. Effendy, "Perkembangan Beberapa Penyakit Daun Jagung Disebabkan Oleh Jamur Di Kecamatan Indralaya Utara Kabupaten Ogan Ilir," *Seminar Nasional Lahan Suboptimal*, no. 1, Art. no. 1, Nov 2019.
- [3] R. A. Pangestu, B. Rahmat, dan F. T. Anggraeny, "IMPLEMENTASI ALGORITMA CNN UNTUK KLASIFIKASI CITRA LAHAN DAN PERHITUNGAN LUAS," vol. 1, no. 1, 2020.
- [4] S. Rizal Amegia, S. Wasiyanti, A. Supriyatna, dan D. F. Saefudin, "Penerapan Algoritma Convolutional Neural Network Dan Arsitektur MobileNet Pada Aplikasi Deteksi Penyakit Daun Padi," *Swabumi*, vol. 9, no. 2, Art. no. 2, Sep 2021, doi: 10.31294/swabumi.v9i2.11678.
- [5] R. Riri, "Klasifikasi Penyakit Tanaman Jagung Melalui Citra Daun Dengan Menggunakan Metode Deep Learning," diploma, Politeknik Negeri Ujung Pandang, 2023. Diakses: 8 Desember 2024. [Daring]. Tersedia pada:  
<https://repository.poliupg.ac.id/id/eprint/10574/>
- [6] C. R. Kotta, D. Paseru, dan M. Sumampouw, "Implementasi Metode Convolutional Neural Network untuk Mendeteksi Penyakit Pada Citra Daun Tomat," *Jurnal Pekommas*, vol. 7, no. 2, Art. no. 2, Des 2022, doi: 10.56873/jpkm.v7i2.4961.
- [7] M. S. Pramono dan A. P. Wibowo, "PENERAPAN CONVOLUTIONAL NEURAL NETWORK UNTUK IDENTIFIKASI PENYAKIT PADA TANAMAN PADI DARI CITRA DAUN MENGGUNAKAN MODEL RESNET-101," *Djtechno: Jurnal Teknologi Informasi*, vol. 5, no. 3, Art. no. 3, Des 2024, doi: 10.46576/djtechno.v5i3.5098.
- [8] S. Ghandi, I. M. Nugroho, dan Y. R. Ramadhan, "PENERAPAN METODE CONVOLUTIONAL NEURAL NETWORK (CNN) DALAM APLIKASI PENDETEKSI PENYAKIT DAUN TANAMAN KENTANG BERBASIS ANDROID," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 8, no. 5, Art. no. 5, Sep 2024, doi: 10.36040/jati.v8i5.10769.
- [9] V. C. Khade dan S. B. Patil, "Customized CNN Model for Multiple Illness Identification in Rice and Maize," *IJRITCC*, vol. 11, no. 8, hlm. 331–341, Sep 2023, doi: 10.17762/ijritcc.v11i8.8006.
- [10] A. A. Kadam, H. Ganatra, A. R. Sawant, dan Y. Sivramkrishnan, "Corn Leaves Disease Detection Using Convolutional Neural Networks [CNN]," *IJSREM*, vol. 07, no. 10, hlm. 1–11, Okt 2023, doi: 10.55041/IJSREM26275.

- [11] D. A. W. Rasa, S. P. Thorve, N. Samuel, dan K. Purwandari, "Handwriting Classification of Numbers and Writing Data using the Convolutional Neural Network Model (CNN)," dalam *2023 International Workshop on Artificial Intelligence and Image Processing (IWAIIIP)*, Des 2023, hlm. 92–95. doi: 10.1109/IWAIIIP58158.2023.10462855.
- [12] E. Song, M. Lee, dan S. Lee, "CarvingNet: Content-Guided Seam Carving Using Deep Convolution Neural Network," *IEEE Access*, vol. 7, hlm. 284–292, 2019, doi: 10.1109/ACCESS.2018.2885347.
- [13] H. Talebi dan P. Milanfar, "Learning to Resize Images for Computer Vision Tasks," 18 Agustus 2021, *arXiv*: arXiv:2103.09950. doi: 10.48550/arXiv.2103.09950.
- [14] T. Cogan, M. Cogan, dan L. Tamil, "MAPGI: Accurate identification of anatomical landmarks and diseased tissue in gastrointestinal tract using deep learning," *Computers in Biology and Medicine*, vol. 111, hlm. 103351, Agu 2019, doi: 10.1016/j.combiomed.2019.103351.
- [15] C. Shorten dan T. M. Khoshgoftaar, "A survey on Image Data Augmentation for Deep Learning," *Journal of Big Data*, vol. 6, no. 1, hlm. 60, Jul 2019, doi: 10.1186/s40537-019-0197-0.
- [16] Z. Zhang, J. Hou, dan Z. Lin, "Exploring Integration methods for Image Data Augmentation," dalam *2024 6th International Conference on Internet of Things, Automation and Artificial Intelligence (IoTAAI)*, Jul 2024, hlm. 707–713. doi: 10.1109/IoTAAI62601.2024.10692583.
- [17] L. Perez dan J. Wang, "The Effectiveness of Data Augmentation in Image Classification using Deep Learning," 13 Desember 2017, *arXiv*: arXiv:1712.04621. doi: 10.48550/arXiv.1712.04621.
- [18] B. A. Riyadi, S. Adi, A. D. Laksito, M. Hayaty, O. Arifin, dan A. Fatkhurohman, "The Effect of Augmentation on Classification Algorithm to Determine Photo Angle," dalam *2023 10th International Conference on Electrical Engineering, Computer Science and Informatics (EECSI)*, Sep 2023, hlm. 254–260. doi: 10.1109/EECSI59885.2023.10295875.
- [19] K. Alomar, H. I. Aysel, dan X. Cai, "Data Augmentation in Classification and Segmentation: A Survey and New Strategies," *Journal of Imaging*, vol. 9, no. 2, Art. no. 2, Feb 2023, doi: 10.3390/jimaging9020046.